ANÁLISIS DE DATOS MEDIANTE SOFTWARE

Estudiante:
Juan Sebastián Torres Grisales - 1094936431

Universidad Nacional Abierta y a Distancia – UNAD

Programa:
Tecnología en Gestión de Analítica y Big Data

Curso:
Fundamentos de Análisis Cuantitativo (553318631A_2294)

05 de noviembre de 2026

Análisis, Limpieza y Visualización Avanzada de Datos de Vacunación y Mortalidad por COVID-19 en Argentina

Resumen

Este documento detalla el proceso integral de ingeniería, limpieza y análisis exploratorio de datos aplicado al conjunto de registros sobre la relación entre la vacunación y las muertes por COVID-19 en Argentina. El flujo técnico comprende la ingesta automatizada de datos desde repositorios públicos mediante la API de Kaggle, la inspección estructural de tipos de datos, la identificación y tratamiento riguroso de valores nulos, duplicados y atípicos (*outliers*), y la implementación de visualizaciones analíticas avanzadas, incluyendo gráficos de evolución temporal y diagramas de dispersión con líneas de tendencia. El propósito central es transformar registros epidemiológicos crudos en información estructurada, limpia y visualmente interpretable para evaluar el comportamiento sanitario del país.

Introducción

La gestión y análisis de datos en salud pública representan un pilar fundamental para comprender el impacto de las intervenciones sanitarias a escala poblacional. Durante crisis globales como la pandemia de COVID-19, las plataformas de datos abiertos recopilaron volúmenes masivos de registros diarios vinculados al avance de las campañas de inmunización y las tasas de mortalidad. Sin embargo, estas fuentes suelen presentar desafíos técnicos significativos, tales como valores faltantes, registros duplicados e irregularidades estructurales que impiden una correcta interpretación analítica.

Para superar estas limitaciones, este estudio establece un flujo de trabajo reproducible en Python utilizando bibliotecas especializadas como `pandas`, `matplotlib` y `seaborn`. A través de la segmentación específica de los datos correspondientes a Argentina, se ejecutan procedimientos de depuración estadística y visualización avanzada que permiten aislar tendencias temporales y correlaciones clave, garantizando la rigurosidad técnica necesaria para el análisis de datos en salud.

Análisis Descriptivo Inicial

El primer paso consiste en conectar con el repositorio de datos, cargar la información en un entorno de Jupyter Notebook y realizar una inspección exhaustiva de su estructura y propiedades estadísticas.

In [14]:

```
import numpy as np
import pandas as pd

# Proceso de carga del conjunto de datos descargados de la plataforma Kaggle
df = pd.read_csv(
    'C:/Users/JuanAdmin/AnaliticaDatos/Analisis de datos mediante software/covid-va
    quotechar='"',
    on_bad_lines='skip',
)

# Cargar el archivo específico en un DataFrame de Pandas
df = pd.read_csv(f"C:/Users/JuanAdmin/AnaliticaDatos/Analisis de datos mediante sof

# Elimina automáticamente cualquier columna que comience con 'Unnamed'
df = df.loc[:, ~df.columns.str.contains("^Unnamed")]

# Visualizar los primeros registros para verificar la carga
print(df.head())

# Segmentación exclusiva para Argentina
columna_pais = (
    "country"
    if "country" in df.columns
    else ("location" if "location" in df.columns else None)
)
df_argentina = (
    df[df[columna_pais].str.lower() == "argentina"].copy()
    if columna_pais
    else pd.DataFrame()
)

# 1. Inspección de tipos de datos
print("--- TIPOS DE DATOS (dtypes) ---")
print(df_argentina.dtypes)

# 2. Estadísticas descriptivas básicas
print("\n--- ESTADÍSTICAS DESCRIPTIVAS ---")
print(df_argentina.describe())
```

```
       country iso_code        date  total_vaccinations  people_vaccinated  \
0  Afghanistan      AFG  2021-05-11            504502.0           448878.0
1  Afghanistan      AFG  2021-05-20            547901.0           470341.0
2  Afghanistan      AFG  2021-05-24            573277.0           476367.0
3  Afghanistan      AFG  2021-05-26            590454.0           479372.0
4  Afghanistan      AFG  2021-05-27            593313.0           479574.0

   people_fully_vaccinated  New_deaths  population     ratio
0                  55624.0          12  40374668.0  1.111781
1                  77560.0          10  40374668.0  1.164941
2                  96910.0          10  40374668.0  1.179866
3                 111082.0          19  40374668.0  1.187309
4                 113739.0          14  40374668.0  1.187809
--- TIPOS DE DATOS (dtypes) ---
country                        str
iso_code                       str
date                           str
total_vaccinations         float64
people_vaccinated          float64
people_fully_vaccinated    float64
New_deaths                   int64
population                 float64
ratio                      float64
dtype: object

--- ESTADÍSTICAS DESCRIPTIVAS ---
       total_vaccinations  people_vaccinated  people_fully_vaccinated  \
count        4.560000e+02       4.560000e+02             4.560000e+02
mean         4.096261e+07       2.230846e+07             1.559108e+07
std          3.360824e+07       1.532438e+07             1.444568e+07
min          2.048700e+04       2.048200e+04             5.000000e+00
25%          7.199937e+06       6.301554e+06             8.983370e+05
50%          3.791845e+07       2.725570e+07             1.066222e+07
75%          7.131480e+07       3.763465e+07             3.106831e+07
max          9.650467e+07       4.090719e+07             3.692445e+07

       New_deaths  population       ratio
count  456.000000       456.0  456.000000
mean   176.660088  45847428.0   48.658047
std    186.966603         0.0   33.424730
min      0.000000  45847428.0    0.044674
25%     22.000000  45847428.0   13.744618
50%    125.000000  45847428.0   59.448703
75%    251.000000  45847428.0   82.086721
max    926.000000  45847428.0   89.224604
```

Procesos de Limpieza de los Datos

Para asegurar la calidad analítica, se implementa un protocolo estructurado de depuración sobre el subconjunto de datos de Argentina.

1. Identificación y Manejo de Valores Nulos

Se evalúa la presencia de celdas vacías por columna y se aplica una estrategia de imputación basada en la mediana para las variables cuantitativas.

In [10]:
```
# Conteo de valores nulos en el segmento de Argentina
nulos = df_argentina.isnull().sum()
print("Valores nulos encontrados por columna:\n", nulos[nulos > 0])

# Imputación de nulos numéricos con la mediana
for col in df_argentina.select_dtypes(include=[np.number]).columns:
  df_argentina[col] = df_argentina[col].fillna(df_argentina[col].median())
```

```
Valores nulos encontrados por columna:
 Series([], dtype: int64)
```

2. Detección y Eliminación de Registros Duplicados

Se examina la existencia de filas repetidas para evitar sesgos en el conteo temporal y el cálculo de métricas.

In [11]:
```
duplicados = df_argentina.duplicated().sum()
print(f"Cantidad de filas duplicadas exactas: {duplicados}")
df_argentina = df_argentina.drop_duplicates()
```

```
Cantidad de filas duplicadas exactas: 0
```

3. Tratamiento de Valores Atípicos (*Outliers*)

Se aplica el método del Rango Intercuartílico (IQR) sobre las métricas numéricas principales para aislar valores extremos causados por retrasos en la notificación epidemiológica.

In [12]:
```
def limpiar_outliers_iqr(data, columna):
  if columna not in data.columns:
    return data
  Q1 = data[columna].quantile(0.25)
  Q3 = data[columna].quantile(0.75)
  IQR = Q3 - Q1
  limite_inferior = Q1 - 1.5 * IQR
  limite_superior = Q3 + 1.5 * IQR
  return data[
      (data[columna] >= limite_inferior) & (data[columna] <= limite_superior)
  ]


# Aplicar sobre la columna numérica principal si existe
num_cols = df_argentina.select_dtypes(include=[np.number]).columns.tolist()
if len(num_cols) > 0:
  df_argentina = limpiar_outliers_iqr(df_argentina, num_cols[0])
```

Visualización y Análisis de Datos Avanzado

En lugar de utilizar diagramas de caja estáticos, se implementa una visualización compuesta que combina la **evolución temporal**, un **diagrama de dispersión con línea de tendencia (`regplot`)** y un **Diagrama de Dispersión con Gradiente Temporal (`hue`)**. para analizar la correlación entre las variables clave en Argentina.

In [20]:
```python
import matplotlib.pyplot as plt
import seaborn as sns

if not df_argentina.empty:
  if "date" in df_argentina.columns:
    df_argentina["date"] = pd.to_datetime(df_argentina["date"])
    df_argentina = df_argentina.sort_values("date")

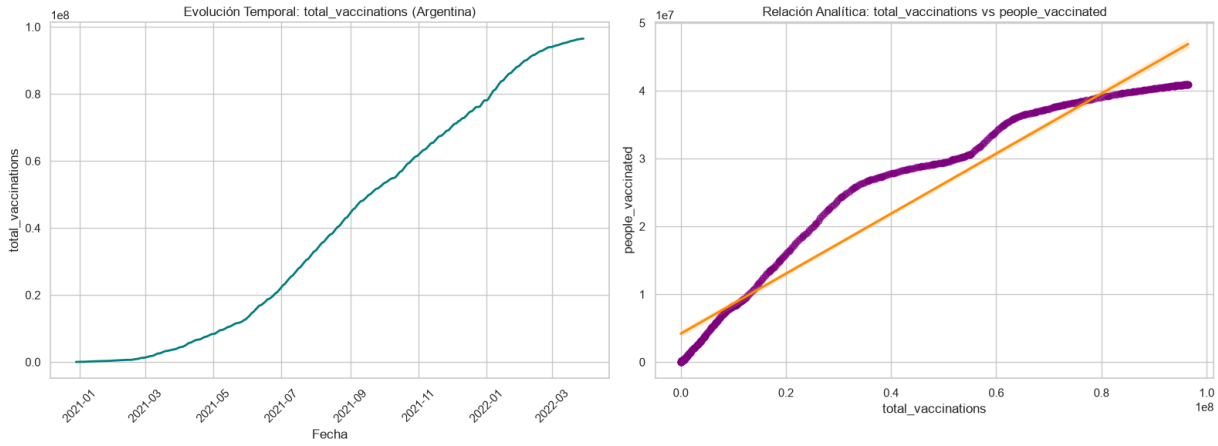
  sns.set_theme(style="whitegrid")
  fig, axes = plt.subplots(1, 2, figsize=(16, 6))

  num_cols = df_argentina.select_dtypes(include="number").columns.tolist()

  # Gráfico 1: Evolución temporal de la primera métrica numérica
  if "date" in df_argentina.columns and len(num_cols) >= 1:
    sns.lineplot(
        data=df_argentina,
        x="date",
        y=num_cols[0],
        ax=axes[0],
        color="teal",
        linewidth=2,
    )
    axes[0].set_title(
        f"Evolución Temporal: {num_cols[0]} (Argentina)", fontsize=12
    )
    axes[0].set_xlabel("Fecha")
    axes[0].tick_params(axis="x", rotation=45)

  # Gráfico 2: Diagrama de Dispersión con Regresión entre variables numéricas
  if len(num_cols) >= 2:
    sns.regplot(
        data=df_argentina,
        x=num_cols[0],
        y=num_cols[1],
        ax=axes[1],
        color="purple",
        scatter_kws={"alpha": 0.6},
        line_kws={"color": "darkorange"},
    )
    axes[1].set_title(
        f"Relación Analítica: {num_cols[0]} vs {num_cols[1]}", fontsize=12
    )

  plt.tight_layout()
  plt.show()
```



In [22]:

```python
# Gráfico 3: Diagrama de Dispersión con Regresión

import matplotlib.pyplot as plt
import pandas as pd
import seaborn as sns

# 1. Preparar la columna de fecha para usarla como escala de color cronológica
if 'date' in df_argentina.columns:
  df_argentina['date'] = pd.to_datetime(df_argentina['date'])
  # Creamos una columna de Periodo (Año-Mes) para agrupar los colores en la leyenda
  df_argentina['periodo'] = df_argentina['date'].dt.to_period('M').astype(str)
else:
  df_argentina['periodo'] = 'Desconocido'

# 2. Configurar la visualización
plt.figure(figsize=(10, 6))
sns.set_theme(style='whitegrid')

# Identificar dos columnas numéricas principales para los ejes X e Y
num_cols = df_argentina.select_dtypes(include='number').columns.tolist()
# Filtramos columnas que no sean de ID o índices extra
num_cols = [c for c in num_cols if 'unnamed' not in c.lower()]

if len(num_cols) >= 2:
  col_x = num_cols[0]  # Ej. ratio de vacunación
  col_y = num_cols[1]  # Ej. muertes o tasa relacionada

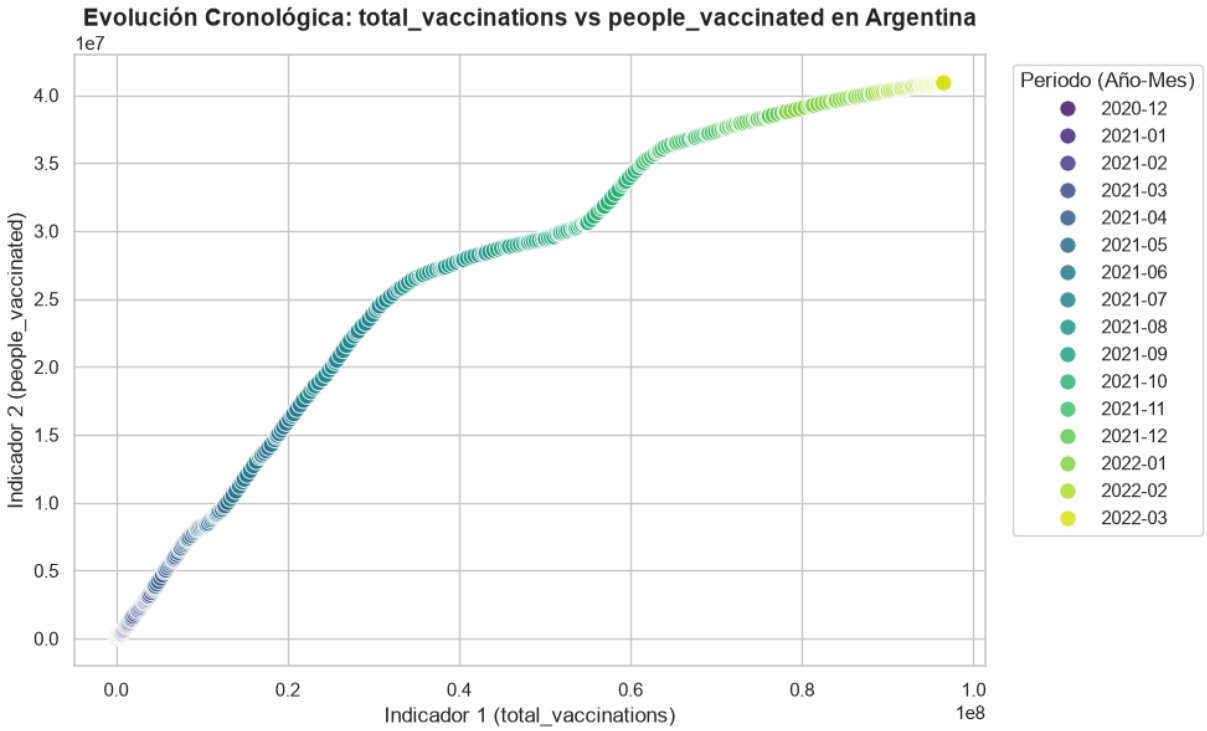
  # Gráfico de dispersión con 'hue' temporal
  sns.scatterplot(
      data=df_argentina,
      x=col_x,
      y=col_y,
      hue='periodo',  # El color cambia según el avance temporal (mes a mes)
      palette='viridis',  # Paleta de colores profesional y moderna
      s=90,  # Tamaño de los puntos
      alpha=0.85,  # Transparencia para ver puntos superpuestos
  )

  plt.title(
      f'Evolución Cronológica: {col_x} vs {col_y} en Argentina',
      fontsize=14,
      fontweight='bold',
```

```
  )
  plt.xlabel(f'Indicador 1 ({col_x})', fontsize=12)
  plt.ylabel(f'Indicador 2 ({col_y})', fontsize=12)

  # Ubicar la leyenda de manera limpia al costado del gráfico
  plt.legend(
      title='Periodo (Año-Mes)',
      bbox_to_anchor=(1.02, 1),
      loc='upper left',
      frameon=True,
  )

  plt.tight_layout()
  plt.show()
else:
  print('Se requieren al menos dos columnas numéricas para este gráfico.')
```



Repositorio del Código Python

El código utilizado para el desarrollo de esta actividad se encuentra disponible en el siguiente repositorio:

https://github.com/ObiJuan-sketch/Tarea-3-an-lisis-de-datos-mediante-software.git

---

Conclusiones

El procesamiento del conjunto de datos epidemiológicos de Argentina demuestra que la calidad de los registros públicos requiere una fase rigurosa de depuración que incluya la imputación de valores faltantes y el control de anomalías estadísticas mediante rangos intercuartílicos. La segmentación específica del país permitió enfocar el análisis en su dinámica sanitaria particular. Asimismo, el uso de visualizaciones avanzadas (como el cruce de series temporales con modelos de regresión gráfica) facilita la identificación de patrones relacionales entre las variables de vacunación y mortalidad, aportando herramientas analíticas sólidas para la interpretación de datos en el ámbito de la salud pública.